

人工智能安全 · 前沿工作汇报

面向 BGP 异常检测的 人工智能方法与安全挑战

AI for Routing Security × Security of AI

汇报方向: BGP 异常检测 (域间路由安全)

汇报人: 柳师宇 学号: 1025040922

汇报大纲

- 01 **研究背景** BGP 协议与互联网路由安全的根本脆弱性
- 02 **安全威胁** 路由劫持、路由泄露、错误配置与真实事件
- 03 **为何用 AI** 传统检测的局限与机器学习的引入
- 04 **方法演进** 传统ML → 时序DL → 图神经网络 → 语义 / 路由树
- 05 **代表性工作** GNN/GAE · BEAM (USENIX'24) · Ares (USENIX'25)
- 06 **AI 安全双视角** 用 AI 护路由 & 检测模型自身的对抗安全
- 07 **挑战与方向** 可解释、鲁棒、可部署的研究规划

背景：BGP —— 互联网的“路由基石”

- **BGP**（边界网关协议）是连接全球数万个自治系统 (AS) 的事实标准域间路由协议。
- 全网约 7 万+ 个 AS 通过交换“路由通告”学习到达每个 IP 前缀的路径。

根本问题：BGP 本身没有内置认证机制。

- 任何 AS 都可以“宣告”任意路由——无论出于攻击还是配置错误。
- 错误 / 恶意路由会在全网快速传播，威胁互联网稳定与安全。
- RPKI / BGPsec 等防护方案因部署不全、兼容性问题，效果有限。

数据平面 vs 控制平面

BGP 工作在控制平面，决定“流量往哪走”

海量、复杂、动态

每天数亿条路由通告，难以人工审计

安全即“信任”

全局路由建立在 AS 之间彼此信任之上

BGP 安全威胁与真实事件

路由劫持 Hijacking

恶意 AS 虚假宣告他人前缀的所有权或更优路径，劫持流量。

路由泄露 Route Leak

本应受限的路由被错误传播，造成大范围流量绕行。

大规模停滞 Outage

由停电、地震等因素引发的大规模路由异常。

真实事件（说明影响之大）：

- **2019** 某公司泄露 7 万+ 条路由，引发大面积可达性问题
- **2021** 某运营商劫持 3.1 万+ 前缀，注册表路由异常传播
- **近年** 某加密货币平台因 BGP 劫持损失约 190 万美元

为什么需要人工智能？

传统方法的局限

- ✗ 依赖人工排查路由，规模不可行
- ✗ 基于规则 / 阈值，难以适应新型异常
- ✗ RPKI/BGPsec，部署不全、覆盖有限
- ✗ 误报多，运维难以信任与落地

AI / 机器学习带来的能力

- ✓ 自动从海量通告中学习，正常 / 异常模式
- ✓ 捕捉时序与图拓扑，结构特征
- ✓ 无监督 / 表示学习，减少人工标注依赖
- ✓ 实时、大规模，在线检测成为可能


AI 方法的技术演进

BGP 异常检测方法的技术演进



趋势：从“手工特征 + 黑盒分类”走向“图结构 + 语义表示 + 可解释”，并降低对人工标注的依赖。

方法图景对比：自动化 × 可解释性



传统 ML：可解释但靠人工

特征 / 阈值清晰，但泛化差、需大量标注

GNN / GAE：自动化强

建模 AS 拓扑；GAE 无监督学“正常行为”

BEAM / Ares：兼顾两者

语义 / 路由树表示，既自动又可解释（理想区）

代表性工作（一）：图神经网络与图自编码器

BGNN / GNN 直接建模 BGP 图

- 把 AS 关系建成图，用**图卷积 / GNN**直接从拓扑结构学习。
- 相比统计特征，**保留结构信息**，对大规模事件更敏感。
- 代表：BGNN、图节点级异常检测（DOMINANT / GCN）与 AS 表示学习。

无监督图自编码器 GAE

- 思路：只学“**正常 BGP 行为**”的表示，偏离即异常。
- 优点：**不依赖异常标签**，不局限于训练集见过的异常类型。
- GAE + MLP 检测器对大规模事件，检测准确率达 **约 99%**。


代表性工作（二）：BEAM —— 语义感知路由异常检测

USENIX Security 2024 · 清华大学等


核心思想

- 用表示学习为每个 AS 学习其独特的“路由角色” (routing role)。
- 异常检测 = 发现新通告引起的“角色突变”。
- 引入 BGP 语义，无需大规模人工标注与手工特征。
- 结果可解释，为运维提供可操作的判断依据。

BEAM 真实 ISP 部署 (USENIX'24)



误报控制对比 (示意)




真实部署：基于 18 个 RouteViews 数据集、110 亿+ 条记录；ISP 实地一月检出 497 个真实异常，平均每天仅 1.65 次误报。

代表性工作（三）：Ares —— 基于路由树的路径劫持检测

USENIX Security 2025 · 清华大学 / 腾讯（最新）

核心思想

- 面向更隐蔽的**路径劫持**（篡改 AS-PATH），超越传统仅针对源劫持的检测。
- 关键观察：路径劫持会在 AS 内触发新的**路由树 (OPRT)**。
- 以**加权编辑距离**量化路由树差异，结合**聚类加速**与启发式规则提高准确率。
- 首个系统化应对**全类型路径劫持**：有效、准确、快速。



实验结果：隐蔽劫持平均检出率 97.2% / 99.3%，误报率仅 1.06%；12 起真实事件均在 5 分钟内检出，优于 SOTA。

参考：Tao et al., "Ares: Comprehensive Path Hijacking Detection via Routing Tree", USENIX Security 2025.

综述视角：检测技术的体系化分类

数据来源	特征类型	模型范式	评价维度
控制平面 (BGP UPDATE)	统计特征	监督学习	检测率 / 召回
数据平面 (探测 / 时延)	时序特征	无监督 / 自监督	误报率
混合多源	图 / 拓扑特征	深度学习 (DL/GNN)	可解释性
	语义 / 表示	表示学习 / LLM	实时性 / 可部署

要点：领域正从“单一特征 + 监督分类”走向“多源融合 + 自监督表示 + 关注可解释与可部署”。

人工智能安全的双重视角

① AI for Security: 用 AI 守护路由

- AI 检测 BGP 劫持 / 泄露, 保护关键基础设施。
- **方向:** 把异常更早、更准地发现。
- **安全要求:** 低误报、可解释、可被运维信任。
- 代表: BEAM、Ares 等将检测推向高精度与可解释。

② Security of AI: 检测模型自身安全

- **对抗样本 / 逃避攻击:** 攻击者精心构造通告绕过检测。
- **数据投毒:** 污染训练数据使模型失效。
- **鲁棒性研究:** 如 PANTS (USENIX'25) 评估并强化网络分类器对抗能力。
- **启示:** 检测器本身必须**可信、鲁棒、可解释**。

深入：Security of AI —— 可信检测器的要求


对抗鲁棒性	数据与后门防护	可解释与可信	隐私与合规
抵御逃避攻击与对抗扰动；对抗训练与鲁棒评估（如 PANTS）。	防范数据投毒 / 后门；保障训练数据与标签质量。	输出可追溯、可复现；为运维提供可操作依据。	跨域 / 跨机构数据共享的隐私与合规边界。

核心论点：“用 AI 护路由”与“护 AI 本身”是同一问题的两面。

只有当检测模型本身足够**鲁棒、可解释、可信赖**，基于 AI 的路由安全防线才能真正被运维信任、落地部署。

参考：Wan et al., “PANTS: ... Adversarial Robustness of Network Traffic Classifiers”, USENIX Security 2025.

关键挑战与开放问题



可解释性

黑盒结果难落地，需给运维可操作依据

对抗鲁棒性

面对逃避攻击与数据投毒的稳健性

标注稀缺

真实异常样本少，倡无监督 / 自监督

实时 & 泛化

在线检测、跨网络 / 跨时间的泛化与低误报

总结

- BGP 是互联网路由基石，但缺乏认证，劫持 / 泄露 / 误配置威胁全局安全。
- AI 成为检测主流：从传统ML → 时序DL → 图神经网络 → 语义 / 路由树表示。
- 代表工作：**BEAM(USENIX'24)** 与 新提出的 **Ares(USENIX'25)** 兼顾高精度、低误报与可解释。
- AI 安全是双向命题：既“用 AI 护路由”，也要保障“检测模型自身”可信鲁棒。
- 我的方向：构建可解释、对抗鲁棒、可部署的 BGP 异常检测框架。

主要参考文献

- 1 Y. Chen et al. “Learning with Semantics: Towards a Semantics-Aware Routing Anomaly Detection System (BEAM).” USENIX Security 2024.
- 2 Y. Tao, C. Zhang, C. An, S. Zhuang, J. Wang, C. Miao. “Ares: Comprehensive Path Hijacking Detection via Routing Tree.” USENIX Security 2025.
- 3 PANTS: Practical Adversarial Robustness Evaluation for Network Traffic / Classifiers. USENIX Security 2025.
- 4 K. Sermpezis et al. “BGP Hijacking Detection and Classification.” (RouteViews / RIPE RIS 数据).
- 5 Comprehensive Surveys on ML/DL/GNN-based BGP Anomaly Detection. Sensors / IEEE COMST, 2023–2024.
- 6 RPKI / BGPsec 相关 RFC 与部署现状分析。

谢谢聆听 · 敬请指正

Q & A

方向：BGP 异常检测 · AI for Routing Security × Security of AI