

以逻辑自洽为桥梁：基于双判断逻辑约束的大模型幻觉检测方法

Logical Consistency as a Bridge: Improving LLM Hallucination Detection via Label Constraint Modeling between Responses and Self-Judgments



南京邮电大学

Hao Mi Qiang Sheng* Shaofei Wang Beizhe Hu Yifan Sun
Zhengjia Wang Hengqi Zeng Yang Li Danding Wang Juan Cao

Institute of Computing Technology, Chinese Academy of Sciences
University of Chinese Academy of Sciences

{mihao24s, shengqiang18z, caojuan}@ict.ac.cn

计算机学院、软件学院、网络空间安全学院

汇报人：1025040941 张利辉

1.研究背景


2.研究方法

3.实验分析

4.总结与思考




1.研究背景



1.研究背景

幻觉检测的两种范式



响应者范式（内在模式）

将LLM作为辨识信号源，通过提取LLM在生成答案时的内部状态（例如中间层表征向量、预测概率、注意力分数等），训练分类器以实现幻觉检测

评估者范式（自我判断）

将LLM作为检测器，让模型自己重新检查、反思并评估刚才生成的内容，看其中是否存在事实错误

1.研究背景

动机与挑战：能否统一两类幻觉检测范式

核心动机

两类范式表面上切入角度不同，本质上都依赖同一能力：模型能否区分“真实”与“虚假”。

现有盲区

以往研究常将二者独立建模，忽略了“响应生成”与“自我判断”之间的逻辑耦合关系。


两个挑战

挑战一：视角不同

响应者视角 vs. 评估者视角，二者如何建立关联？

挑战二：机制不同

连续神经特征 vs. 离散符号判断，二者如何协同优化？




论文提出 **LaaB** (Logical Consistency-as-a-Bridge)：以逻辑一致性作为桥梁，将两类范式联合建模。

LaaB 框架中的符号汇总

Table 1: Summary of notations in LaaB Framework


<i>Response</i>		<i>Self-Judgment</i>	
Q_r	User query	Q_j	Evaluation prompt on O_r
O_r	LLM response to Q_r	$O_j \in \{\text{"Yes"}, \text{"No"}\}$	LLM response to Q_j (Verbal judge)
F_r	Intrinsic features for O_r	F_j	Intrinsic features for O_j
D_r	Detector over F_r	D_j	Detector over F_j
$L_r \in \{0, 1\}$	Ground-truth for O_r (1: factual)	$L_j \in \{0, 1\}$	Ground-truth for O_j (Meta judge)
$\hat{L}_r \in \{0, 1\}$	Predicted label for O_r	$\hat{L}_j \in \{0, 1\}$	Predicted label for O_j
S_r	Predicted distribution from D_r	S_j	Predicted distribution from D_j

2.研究方法



LaaB 幻觉检测框架图


a.原始回答幻觉建模



$$D_r(F_r) \rightarrow S_r = (S_{(r,hallu)}, S_{(r,real)})$$
$$F_r \in \{H_r, P_r, A_r\}$$

特征	含义
Hidden States H_r	模型生成回答后的内部语义状态
Prediction Logits P_r	模型生成回答时的置信度/犹豫程度
Attention Scores A_r	模型回答时关注了哪些上下文

b.自我判断幻觉建模



$$D_j(F_j) \rightarrow S_j = (S_{(j,hallu)}, S_{(j,real)})$$
$$F_j \in \{H_j, P_j, A_j\}$$

特征	含义
Hidden States H_j	生成 Yes/No 时的内部语义状态
Prediction Logits P_j	模型输出 Yes/No 时的置信度差异
Attention Scores A_j	模型回答时关注了哪些上下文

c.逻辑约束下的互学习


Self-Judgment (O_j)	Interpretation	Target (L_r)
“Yes”	Affirmation: The LLM supports the original response. Keep labels consistent.	L_j
“No”	Negation: The LLM refutes. Reverse the factuality.	$1 - L_j$

符号	含义
O_j	模型的自我判断，取值是 Yes 或 No
L_r	原回答的真实标签，1 表示真实，0 表示幻觉
L_j	自我判断的真实标签，1 表示判断正确，0 表示判断错误

自我判断 O_j	含义	对原回答标签 L_r 的推导
Yes	模型支持原回答	$L_r = L_j$
No	模型否定原回答	$L_r = 1 - L_j$

2.研究方法

c.逻辑约束下的互学习



标签约束 L_r & L_j	
(自我判断, L_j)	L_r
("Yes", REAL)	REAL
("Yes", FAKE)	FAKE
("No", REAL)	FAKE
("No", FAKE)	REAL

$$\mathcal{L}_{\text{Logic}} = \begin{cases} \mathcal{L}_{\text{Huber}}(S_{r,\text{hallu}}, S_{j,\text{hallu}}), & \text{if } O_j = \text{"Yes"}, \\ \mathcal{L}_{\text{Huber}}(S_{r,\text{hallu}}, S_{j,\text{real}}), & \text{if } O_j = \text{"No"}. \end{cases} \quad (2)$$

$$\mathcal{L}_{\text{Logic},r} = \log \left(1 + \frac{S_j(L_j)}{S_r(L_r)} \right) \cdot \mathcal{L}_{\text{Logic}}, \quad (3)$$

$$\mathcal{L}_{\text{Logic},j} = \log \left(1 + \frac{S_r(L_r)}{S_j(L_j)} \right) \cdot \mathcal{L}_{\text{Logic}}, \quad (4)$$

$$\mathcal{L}_* = \mathcal{L}_{\text{CE},*} + \alpha_* \mathcal{L}_{\text{Logic},*}. \quad (5)$$

$$\alpha_* = \frac{\left\| \nabla_{\theta_*^{-1}} \mathcal{L}_{\text{CE},*} \right\|_2}{\left\| \nabla_{\theta_*^{-1}} \mathcal{L}_{\text{Logic},*} \right\|_2 + \epsilon}. \quad (6)$$

$$\mathcal{L}_{\text{Joint}} = \mathcal{L}_{\text{CE},r} + \mathcal{L}_{\text{CE},j} + \alpha \mathcal{L}_{\text{Logic}}. \quad (7)$$

3.实验分析



实验设置

数据集

TriviaQA
MMLU
NQ_Open
HaluEval

大语言模型

Llama-3.1-8B
Llama-3.1-70B
Qwen-2.5-32B
Mistral-7B

基线方法

Self-Judge	自我判断
SAPLMA	Hidden states, 隐藏状态
Logits Lens	Prediction logits, 预测概率
Lookback Lens	Attention patterns, 注意力模式
SelfCheckGPT	多次采样一致性
Eigen-Score	多次生成表示的语义不确定性

评价指标

Macro-F1: 类别均衡表现
Accuracy: 整体正确率

数据构造流程

1

LLM 生成回答

给定问题 Q_r , 得到
原始回答 O_r



2

LLM 自我判断

用评估提示 Q_j 得
到 Yes/No



3

标注事实性

标注原回答标签 L_r
与自我判断标签 L_j



4

训练/验证/测试

按照 7:1:2 划分数
据

3.实验分析



变体实验

变体	含义
LaaB D_j	推理时只使用自我判断检测器 D_j
LaaB $D_r + D_j$	推理时同时使用 D_r 和 D_j , 并融合两者分数
LaaB	标准版本, 训练时用两支, 推理时只用 D_r

泛化实验

Method	TriviaQA	MMLU	NQ_Open	HaluEval
SAPLMA	73.90	56.19	65.76	67.49
+LaaB	78.18	59.31	68.33	70.25
Logits Lens	73.05	56.65	57.25	67.78
+LaaB	73.13	55.05	61.06	68.89
Lookback Lens	74.09	60.05	65.44	68.25
+LaaB	72.61	63.61	68.00	69.92


Method	Variant	TriviaQA		MMLU		NQ_Open		HaluEval	
		macF1	Acc	macF1	Acc	macF1	Acc	macF1	Acc
SAPLMA	LaaB	78.74	82.09	71.77	73.25	73.10	77.13	77.20	77.60
	LaaB (D_j)	75.71	81.26	69.23	71.50	71.72	77.29	77.36	77.99
	LaaB ($D_r + D_j$)	79.21	83.12	71.70	73.39	74.16	78.51	77.92	78.43
Logits Lens	LaaB	75.11	78.88	66.72	70.65	65.72	68.90	72.29	73.04
	LaaB (D_j)	45.17	72.64	62.57	69.28	41.02	67.07	70.91	71.65
	LaaB ($D_r + D_j$)	73.97	81.72	63.00	69.66	67.89	76.07	75.24	75.76
Lookback Lens	LaaB	73.58	77.44	70.96	72.50	72.63	75.46	77.00	77.54
	LaaB (D_j)	69.42	78.63	61.89	69.19	67.87	75.61	71.99	73.10
	LaaB ($D_r + D_j$)	75.26	80.74	63.69	69.90	72.24	77.44	76.61	77.43

结论

- 只用 D_j 推理通常不如标准LaaB,说明原回答内部特征仍然是主要检测线索
- $D_r + D_j$ 只带来有限增益, 却会增加额外自我判断成本。
- 跨数据集泛化实验中, 多数 + LaaB 仍提升, 说明逻辑约束有助于减少数据集特定噪声。

3.实验分析

进一步分析一




很多原来 D_r 判断错的样本被修正了

LaaB 保留了大多数 D_r 原本判断正确的样本

少量两个分支原本都错的样本，也被 LaaB 修正了

进一步分析二



LaaB 在大多数长度区间上都能提升性能，尤其对较长回答提升更明显。

4.总结与思考

总结：LaaB 用逻辑一致性连接两类幻觉检测范式

统一视角

将内部神经信号与外部自我判断联系起来，缓解两类范式割裂

元判断机制

不直接相信模型的 Yes/No，而是检测自我判断本身是否可靠

高效推理

训练时双分支互学习，推理时只保留 D_r ，兼顾效果与成本

局限性

Yes/No 强制判断带来噪声

真实场景中，模型可能更适合回答“不确定”，但 LaaB 将自我判断限制为二分类

软逻辑约束不能保证完全一致

如果 D_r 和 D_j 初始都判断错误，LaaB 不一定能纠正

依赖模型内部状态

需要访问 hidden states、logits、attention，更适合模型服务提供商，不适合普通用户

未来工作

长文本幻觉检测

多模态幻觉检测

结合事实核查



南京邮电大学

感谢您的观看

计算机学院、软件学院、网络空间安全学院

汇报人：1025040941 张利辉